Застосування мереж Колмогорова-Арнольда до задач комп'ютерного зору

12 червня, 2025

Виконав: Захаров Д.О.[1]
Науковий керівник: Ігнатович С.Ю.[2]
Рецензент: Волощук О.Б.[3]

[1]Студент групи МП41 IV курсу (перший бакалаврський рівень), спеціальності 113 "Прикладна математика" освітньої програми "Прикладна математика".
[2]Доктор фіз.-мат. наук, професор кафедри прикладної математики.
[3]Доцент кафедри штучного інтелекту Харківського національного університету радіоелектроніки.

Вступ

Опис типової задачі

- На вхід подається певний набір даних $\mathcal{D}$. Найчастіше, це набір пар $\{(\boldsymbol{x}_n, \boldsymbol{y}_n)\}_{1 \leq n \leq N} \subseteq \mathcal{X} \times \mathcal{Y}$ (*supervised learning*).

Опис типової задачі

- На вхід подається певний набір даних $\mathcal{D}$. Найчастіше, це набір пар $\{(\boldsymbol{x}_n, \boldsymbol{y}_n)\}_{1 \leq n \leq N} \subseteq \mathcal{X} \times \mathcal{Y}$ (*supervised learning*).
- Часто ми хочемо знайти так звану *модель* $f : \mathcal{X} \to \mathcal{Y}$, для якої $f(\boldsymbol{x}_n) \approx \boldsymbol{y}_n$: ми передбачаємо значення $\boldsymbol{y}_n$ на основі $\boldsymbol{x}_n$.

Опис типової задачі

- На вхід подається певний набір даних $\mathcal{D}$. Найчастіше, це набір пар $\{(\boldsymbol{x}_n, \boldsymbol{y}_n)\}_{1 \leq n \leq N} \subseteq \mathcal{X} \times \mathcal{Y}$ (*supervised learning*).
- Часто ми хочемо знайти так звану *модель* $f : \mathcal{X} \to \mathcal{Y}$, для якої $f(\boldsymbol{x}_n) \approx \boldsymbol{y}_n$: ми передбачаємо значення $\boldsymbol{y}_n$ на основі $\boldsymbol{x}_n$.
- Функцію f ми маємо підібрати з певного класу $\mathcal{F}$ так, щоб за неї досягався певний мінімум ($\widehat{f} := \arg\min_{f \in \mathcal{F}} \mathcal{L}(\mathcal{D}|f)$).

Опис типової задачі

- На вхід подається певний набір даних $\mathcal{D}$. Найчастіше, це набір пар $\{(\boldsymbol{x}_n, \boldsymbol{y}_n)\}_{1 \leq n \leq N} \subseteq \mathcal{X} \times \mathcal{Y}$ (*supervised learning*).
- Часто ми хочемо знайти так звану *модель* $f : \mathcal{X} \to \mathcal{Y}$, для якої $f(\boldsymbol{x}_n) \approx \boldsymbol{y}_n$: ми передбачаємо значення $\boldsymbol{y}_n$ на основі $\boldsymbol{x}_n$.
- Функцію f ми маємо підібрати з певного класу $\mathcal{F}$ так, щоб за неї досягався певний мінімум ($\widehat{f} := \arg\min_{f \in \mathcal{F}} \mathcal{L}(\mathcal{D}|f)$).

Ціль дипломної роботи

✓ Зараз $\mathcal{F}$ — це параметризоване сімейство MLP архітектур нейронних мереж. В роботі, ми дослідили, чому такий вибір взагалі працює на практиці.

Опис типової задачі

- На вхід подається певний набір даних $\mathcal{D}$. Найчастіше, це набір пар $\{(\boldsymbol{x}_n, \boldsymbol{y}_n)\}_{1 \leq n \leq N} \subseteq \mathcal{X} \times \mathcal{Y}$ (*supervised learning*).
- Часто ми хочемо знайти так звану *модель* $f : \mathcal{X} \to \mathcal{Y}$, для якої $f(\boldsymbol{x}_n) \approx \boldsymbol{y}_n$: ми передбачаємо значення $\boldsymbol{y}_n$ на основі $\boldsymbol{x}_n$.
- Функцію f ми маємо підібрати з певного класу $\mathcal{F}$ так, щоб за неї досягався певний мінімум ($\widehat{f} := \arg\min_{f \in \mathcal{F}} \mathcal{L}(\mathcal{D}|f)$).

Ціль дипломної роботи

✓ Зараз $\mathcal{F}$ — це параметризоване сімейство MLP архітектур нейронних мереж. В роботі, ми дослідили, чому такий вибір взагалі працює на практиці.

✓ Ми дослідили альтернативну парадигму вибору $\mathcal{F}$ — мережі Колмогорова-Арнольда (KAN), а також розширили конструкцію KAN на конволюційні нейронні мережі.

Задача машинного навчання: приклад

Задача : $\hat{\boldsymbol{\theta}} := \arg\min_{\boldsymbol{\theta}\in\Theta} \mathcal{L}(\mathcal{D}|f_{\boldsymbol{\theta}})$ де $f_\theta(\boldsymbol{x}) = \theta_0 + \sum_{i=1}^{n} \theta_i x_i$

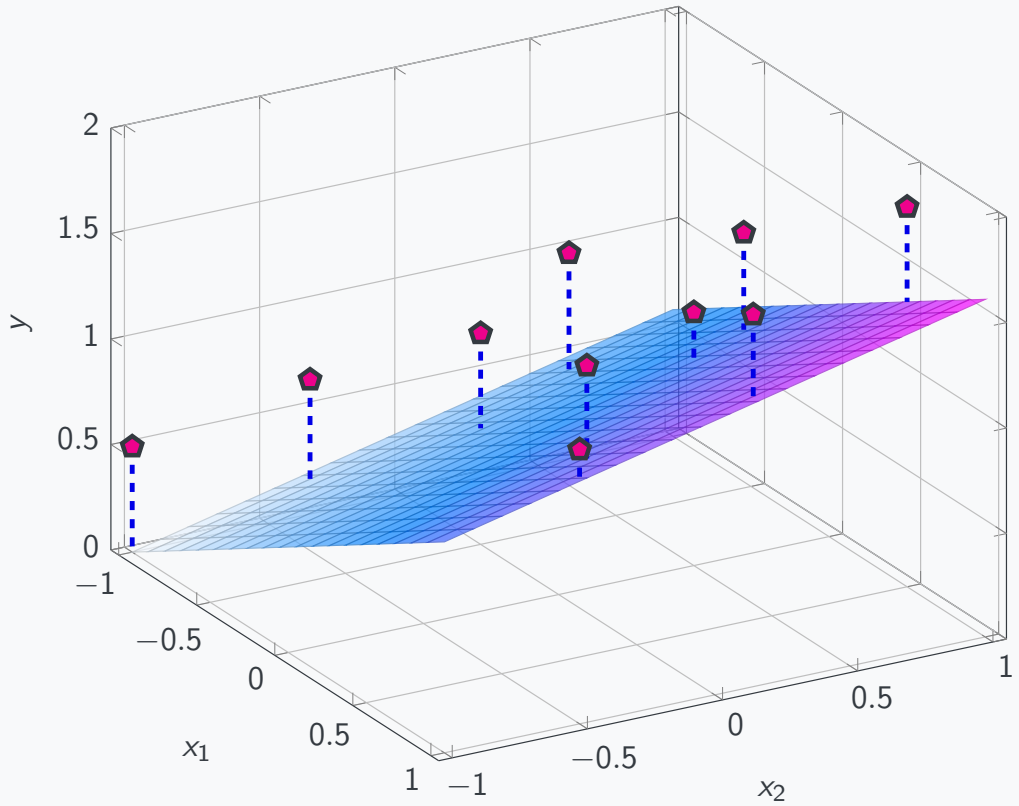


Рис.: Приклад багатовимірної лінійної регресії для $\boldsymbol{x}_n \in \mathbb{R}^2$, $y_n \in \mathbb{R}$. Ціль підібрати площину $f(\boldsymbol{x}|\beta, w_1, w_2) := \beta + w_1 x_1 + w_2 x_2$ так, щоб втрата $\mathcal{L}(\mathcal{D}|\beta, w_1, w_2) = \frac{1}{N}\sum_{n=1}^{N} \|f(\boldsymbol{x}_n) - y_n\|^2$ була мінімальною.

Актуальність нейронних мереж

У попередніх наших роботах [ZKF24; Kuz+24; KZF24] ми, зокрема, досліджували задачу кібербезпеки біометричних даних:

Робота	Рік, Журнал	Модель	Набір даних
[ZKF24]	2023, Multimedia Tools and Applications (Springer)	$f : \mathcal{I} \to \{0,1\}^{128}$: Бінарний вектор характеристик	Зображення та ідентифікатори людей
[Kuz+24]	2024, Computers & Security (Elsevier)	$f : \mathcal{I} \to \{0,1\}$: Класифікатор живності	Зображення та біти "фейк/не фейк"
[KZF24]	2024, Engineering Applications of AI (Elsevier)	$f : \mathcal{I} \to \mathcal{I}$: "Геш" значення фотографії людини	Зображення та ідентифікатори людей

Табл.: Приклади наших робіт з біометрії. $\mathcal{I}$ — множина зображень.

Питання нашого дослідження

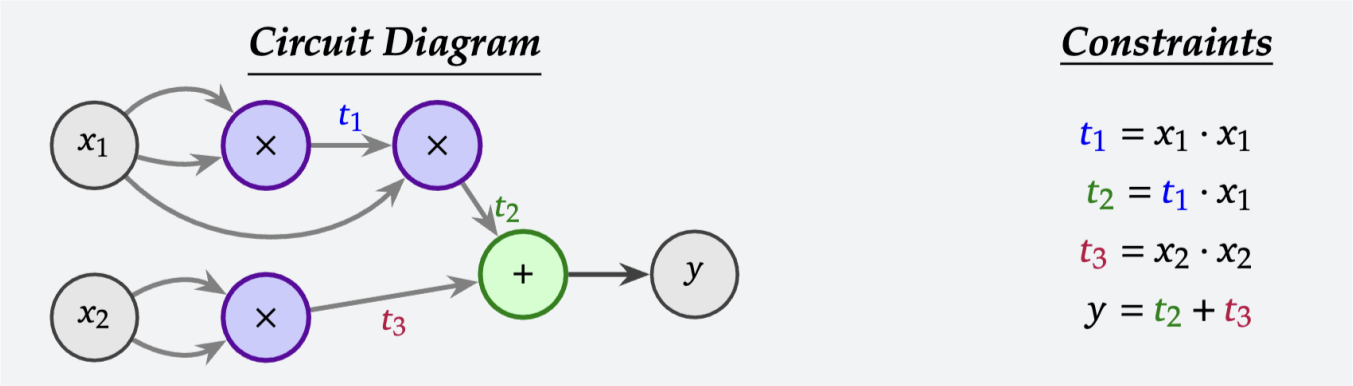
Зараз ці задачі розв'язуються за допомогою MLP парадигми. Чи є *потенціал* у використанні KAN архітектур для розв'язання подібних задач з комп'ютерного зору?

Актуальність KAN архітектур

- **“Плато” LLM:** Згідно багатьом дослідженням (напр. “On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?” [Ben+21]), ми досягаємо деякого “плато” у розвитку нейронних мереж. Значить, нам потрібні нові підходи до побудови архітектур.

Актуальність KAN архітектур

- **“Плато” LLM:** Згідно багатьом дослідженням (напр. “On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?” [Ben+21]), ми досягаємо деякого “плато” у розвитку нейронних мереж. Значить, нам потрібні нові підходи до побудови архітектур.
- **Кібербезпека та нейронні мережі:** У сфері кібербезпеки, актуальним питанням стає написання нейронних мереж у вигляді арифметичних ланцюгів (arithmetical circuits). Отже, потрібно досліджувати структури мереж, що можуть бути “дружелюбними” до таких арифметичних схем.



MLP vs KAN

MLP парадигма

Розглянемо сучасну парадигму побудов архітектур — MLP.

Апроксимація функцій лінійною комбінацією сігмоїдів

Робота Цибенко [Cyb89] присвячена на той час відомій апроксимації функції $f : \mathbb{R}^m \to \mathbb{R}$ за допомогою наступної суми:

$$\hat{f}(\boldsymbol{x}) = \sum_{j=1}^{n} \alpha_j \sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + \beta_j), \quad \sigma(-\infty) = 0,\ \sigma(+\infty) = 1,$$

MLP парадигма

Розглянемо сучасну парадигму побудов архітектур — MLP.

Апроксимація функцій лінійною комбінацією сігмоїдів

Робота Цибенко [Cyb89] присвячена на той час відомій апроксимації функції $f : \mathbb{R}^m \to \mathbb{R}$ за допомогою наступної суми:

$$\hat{f}(\boldsymbol{x}) = \sum_{j=1}^{n} \alpha_j \sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + \beta_j), \quad \sigma(-\infty) = 0,\ \sigma(+\infty) = 1,$$

- По суті, лінійна комбінація виразів $\{\sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + \beta_j)\}_{1 \le j \le n}$.
- n — кількість нейронів у прихованому шарі.

MLP парадигма

Розглянемо сучасну парадигму побудов архітектур — MLP.

Апроксимація функцій лінійною комбінацією сігмоїдів

Робота Цибенко [Cyb89] присвячена на той час відомій апроксимації функції $f : \mathbb{R}^m \to \mathbb{R}$ за допомогою наступної суми:

$$\hat{f}(\boldsymbol{x}) = \sum_{j=1}^{n} \alpha_j \sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + \beta_j), \quad \sigma(-\infty) = 0,\ \sigma(+\infty) = 1,$$

- По суті, лінійна комбінація виразів $\{\sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + \beta_j)\}_{1 \le j \le n}$.
- n — кількість нейронів у прихованому шарі.

Питання

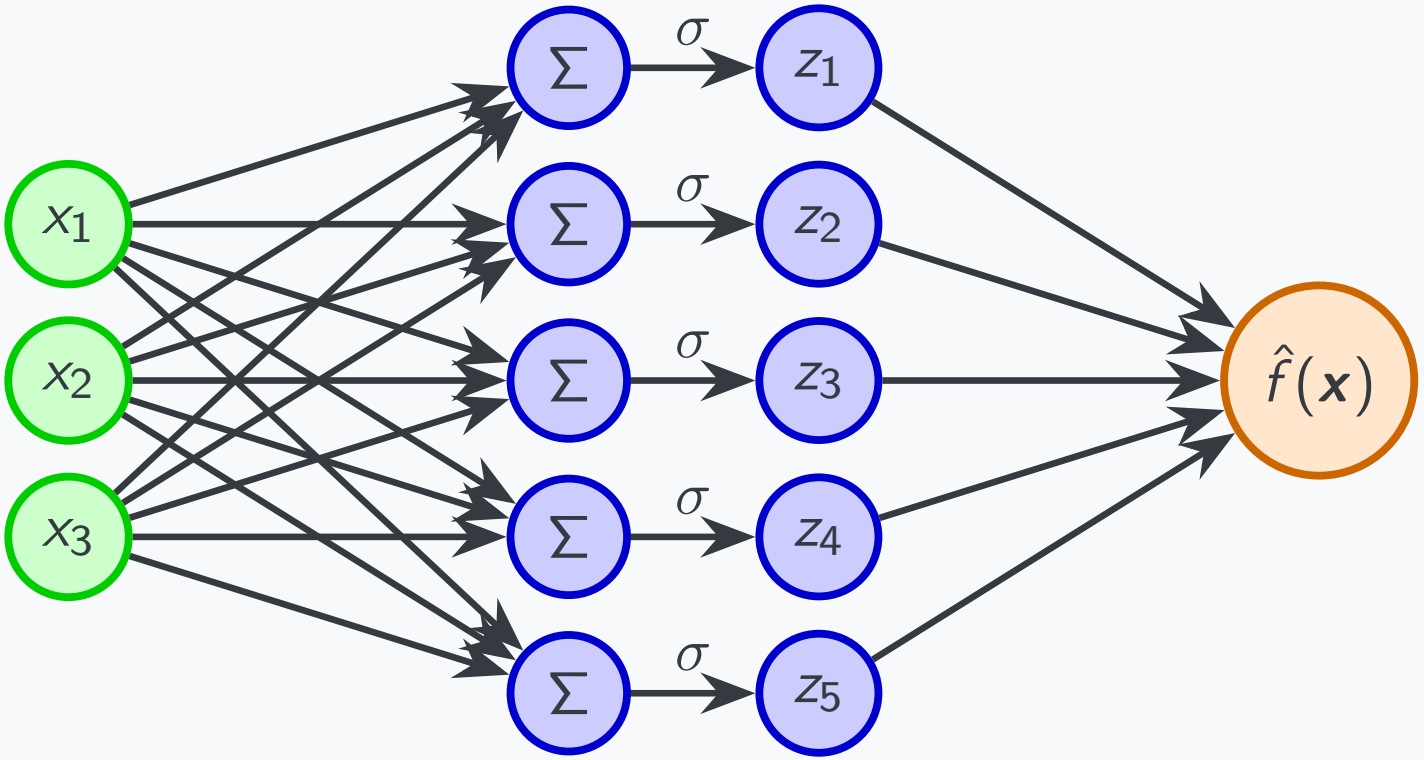
Який клас функцій може апроксимувати така модель?

Візуалізація Архітектури Цибенко

Вхідний шар
m нейронів

Прихований шар
n нейронів

Вихідний шар
1 нейрон



Теорема Цибенко

- $\mathcal{Q}_m = [0,1]^m$ є m-вимірним одиничним гіперкубом.
- $\mathcal{C}(\mathcal{Q}_m)$ — простір неперервних функцій $f : \mathcal{Q}_m \to \mathbb{R}$.
- Норма функції f на $\mathcal{C}(\mathcal{Q}_m)$: $\|f\|_{\mathcal{Q}_m} = \sup_{\boldsymbol{x} \in \mathcal{Q}_m} |f(\boldsymbol{x})|$.

Theorem (Цибенко)

Нехай σ будь-яка неперервна сігмоїдальна функція. Суми вигляду $\hat{f}(\boldsymbol{x}) = \sum_{j=1}^{n} \alpha_j \sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + \beta_j)$ є щільними у $\mathcal{C}(\mathcal{Q}_m)$ та $L^1(\mathcal{Q}_m)$. Іншими словами, для будь-якої функції $f \in \mathcal{C}(\mathcal{Q}_m)$ та $\varepsilon > 0$, існує сума $\hat{f}(\boldsymbol{x})$ така, що:

1. $|\hat{f}(\boldsymbol{x}) - f(\boldsymbol{x})| < \varepsilon$ *для всіх* $\boldsymbol{x} \in \mathcal{Q}_m$.
2. $\int_{\mathcal{Q}_m} |\hat{f}(\boldsymbol{x}) - f(\boldsymbol{x})| d\boldsymbol{x} < \varepsilon$.

Теорема Цибенко

- $\mathcal{Q}_m = [0,1]^m$ є m-вимірним одиничним гіперкубом.
- $\mathcal{C}(\mathcal{Q}_m)$ — простір неперервних функцій $f : \mathcal{Q}_m \to \mathbb{R}$.
- Норма функції f на $\mathcal{C}(\mathcal{Q}_m)$: $\|f\|_{\mathcal{Q}_m} = \sup_{\boldsymbol{x} \in \mathcal{Q}_m} |f(\boldsymbol{x})|$.

Theorem (Цибенко)

Нехай σ будь-яка неперервна сігмоїдальна функція. Суми вигляду $\hat{f}(\boldsymbol{x}) = \sum_{j=1}^{n} \alpha_j \sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + \beta_j)$ є щільними у $\mathcal{C}(\mathcal{Q}_m)$ та $L^1(\mathcal{Q}_m)$. Іншими словами, для будь-якої функції $f \in \mathcal{C}(\mathcal{Q}_m)$ та $\varepsilon > 0$, існує сума $\hat{f}(\boldsymbol{x})$ така, що:

1. $|\hat{f}(\boldsymbol{x}) - f(\boldsymbol{x})| < \varepsilon$ *для всіх* $\boldsymbol{x} \in \mathcal{Q}_m$.
2. $\int_{\mathcal{Q}_m} |\hat{f}(\boldsymbol{x}) - f(\boldsymbol{x})| d\boldsymbol{x} < \varepsilon$.

Висновок

$\sum_{j=1}^{n} \alpha_j \sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + \beta_j)$ апроксимує довільну функцію на $\mathcal{C}(\mathcal{Q}_m)$.

Практична реалізація

Додаток

У дипломній роботі ми написали програму, що для заданого бінарного розбиття $\mathcal{P}_0, \mathcal{P}_1$ квадрату $[0,1]^2$, будує оптимальний класифікатор $\hat{f}$.

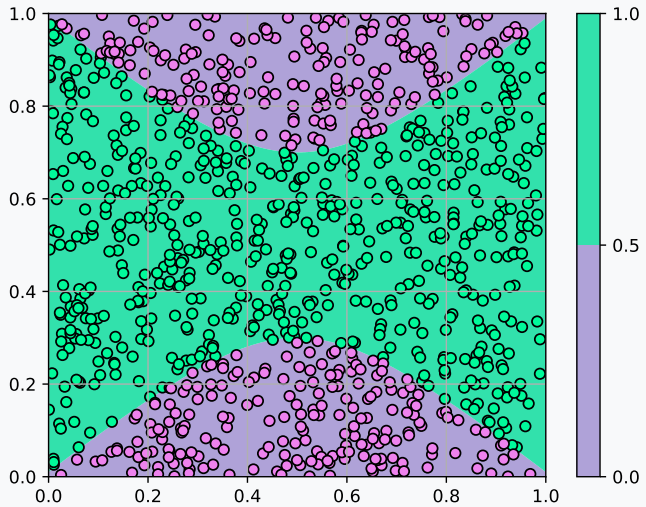


Рис.: Правильне розбиття квадрату $\mathcal{P}_0, \mathcal{P}_1$.

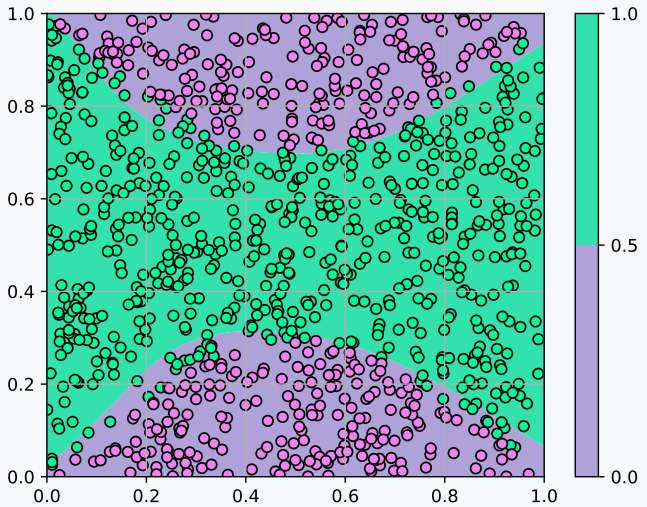


Рис.: Розбиття, знайдене класифікатором $\hat{f}$.

Узагальнення: MLP

1. Замість сігмоїду σ, використовуються інші **нелінійні** активаційні функції $\phi : \mathbb{R} \to \mathbb{R}$ (напр., $\phi(x) = \max\{0, x\}$).
2. Замість двох шарів, може бути довільна кількість шарів.

Узагальнення: MLP

1. Замість сігмоїду σ, використовуються інші **нелінійні** активаційні функції $\phi : \mathbb{R} \to \mathbb{R}$ (напр., $\phi(x) = \max\{0, x\}$).
2. Замість двох шарів, може бути довільна кількість шарів.

Definition (Багатошарова модель персептронів (MLP))

Таким чином, узагальнена архітектура:

$$\boldsymbol{x}^{\langle j+1\rangle} = \phi^{\langle j\rangle}(\boldsymbol{z}^{\langle j\rangle}), \quad \boldsymbol{z}^{\langle j\rangle} = \boldsymbol{W}^{\langle j\rangle}\boldsymbol{x}^{\langle j\rangle} + \boldsymbol{\beta}^{\langle j\rangle}, \quad j = 0, \ldots, \ell - 1,$$

Узагальнення: MLP

1. Замість сігмоїду σ, використовуються інші **нелінійні** активаційні функції $\phi : \mathbb{R} \to \mathbb{R}$ (напр., $\phi(x) = \max\{0, x\}$).
2. Замість двох шарів, може бути довільна кількість шарів.

Definition (Багатошарова модель персептронів (MLP))

Таким чином, узагальнена архітектура:

$$\boldsymbol{x}^{\langle j+1\rangle} = \phi^{\langle j\rangle}(\boldsymbol{z}^{\langle j\rangle}), \quad \boldsymbol{z}^{\langle j\rangle} = \boldsymbol{W}^{\langle j\rangle}\boldsymbol{x}^{\langle j\rangle} + \boldsymbol{\beta}^{\langle j\rangle}, \quad j = 0, \ldots, \ell - 1,$$

Зауваження

У дипломній роботі, ми розглянули питання: (a) навіщо потрібно більше двох шарів, (b) які бувають узагальнення архітектури MLP та (c) навіщо інші активаційні функції.

Теорема Колмогорова-Арнольда

Основна гіпотеза 13 проблеми Гільберта

Існує неперервна функція $f : \mathcal{Q}_3 \to \mathbb{R}$, що не може бути виражена як композиція та сума неперервних функцій $\phi_1, \ldots, \phi_N \in \mathcal{C}(\mathbb{R}^2)$.

Теорема Колмогорова-Арнольда

Основна гіпотеза 13 проблеми Гільберта

Існує неперервна функція $f : \mathcal{Q}_3 \to \mathbb{R}$, що не може бути виражена як композиція та сума неперервних функцій $\phi_1, \ldots, \phi_N \in \mathcal{C}(\mathbb{R}^2)$.

Проте, у 1957 році Колмогоров показав обернене.

Definition (Теорема Колмогорова (1957, [N57]))

Для будь-якого натурального $m \geq 2$, існують неперервні функції $\phi_{p,q} \in \mathcal{C}([0,1])$ такі, що для будь-якої функції $f \in \mathcal{C}(\mathcal{Q}_m)$ знайдуться неперервні функції $\Phi_1, \ldots, \Phi_{2m+1} \in \mathcal{C}(\mathbb{R})$ такі, що

$$f(x_1, \ldots, x_m) = \sum_{q=1}^{2m+1} \Phi_q \left(\sum_{p=1}^{m} \phi_{p,q}(x_p) \right)$$

Мережа Колмогорова-Арнольда(KAN)

Зауваження

До роботи 2024 року [Liu+24b], ідею такої репрезентації вважали недосяжною через "поганість" функцій $\phi_{p,q}$ та Φ_q.

Мережа Колмогорова-Арнольда(KAN)

Зауваження

До роботи 2024 року [Liu+24b], ідею такої репрезентації вважали недосяжною через "поганість" функцій $\phi_{p,q}$ та Φ_q.

Definition (З'єднання KAN Мережі [Liu+24b])

З'єднання KAN Мережі між шарами розміру n (вхід) та m (вихід) — це матриця $\mathbf{\Phi} = \{\phi_{q,p}\}_{1\leq p\leq n, 1\leq q\leq m}$, де кожна функція параметризована, а наступне значення активації $\boldsymbol{y} = \mathbf{\Phi} \circ \boldsymbol{x}$.

$$\begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} = \begin{bmatrix} \phi_{1,1} & \cdots & \phi_{1,n} \\ \vdots & \ddots & \vdots \\ \phi_{m,1} & \cdots & \phi_{m,n} \end{bmatrix} \circ \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \triangleq \begin{bmatrix} \sum_{p=1}^{n} \phi_{1,p}(x_p) \\ \vdots \\ \sum_{p=1}^{n} \phi_{m,p}(x_p) \end{bmatrix}$$

Мережа Колмогорова-Арнольда(KAN), cont.

Definition (Архітектура KAN [Liu+24b])

Мережа Колмогорова-Арнольда — це композиція ℓ з'єднань:

$$\hat{f}_{\text{KAN}}(\boldsymbol{x}) = \boldsymbol{\Phi}^{\langle \ell-1 \rangle} \circ \cdots \circ \boldsymbol{\Phi}^{\langle 1 \rangle} \circ \boldsymbol{\Phi}^{\langle 0 \rangle} \circ \boldsymbol{x}.$$

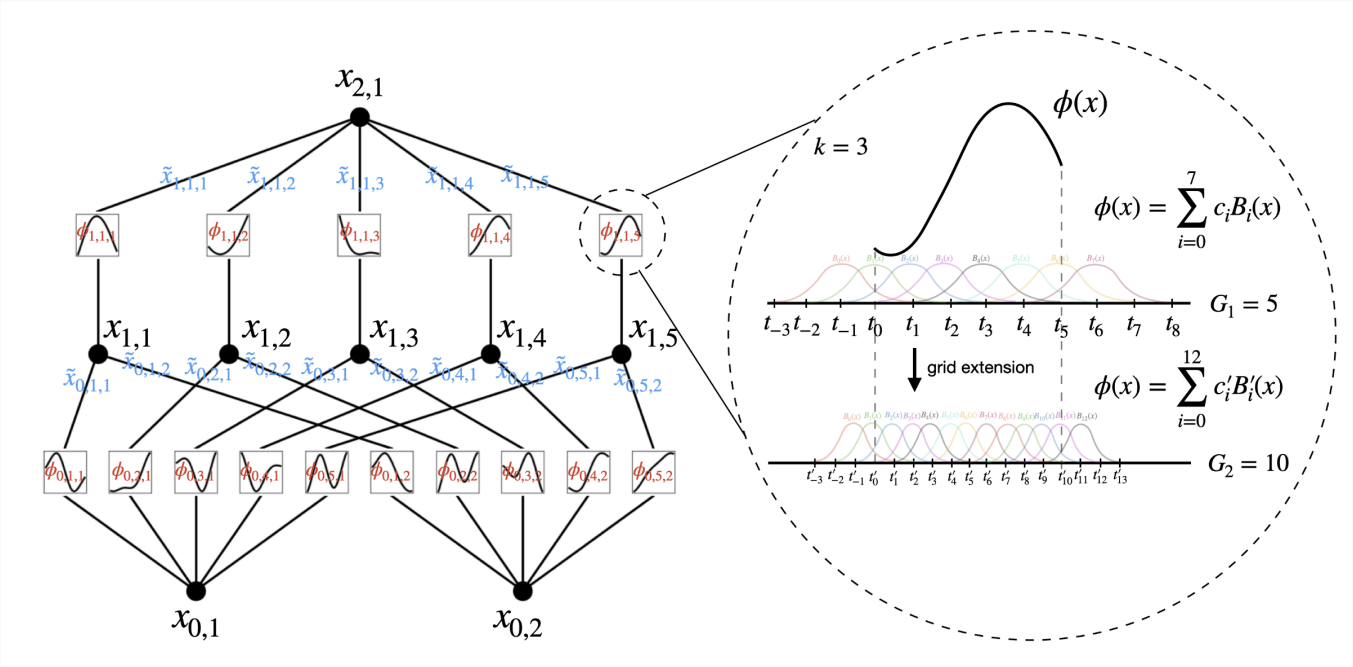


Рис.: Архітектура мережі Колмогорова-Арнольда з оригінальної роботи [Liu+24b].

Інтерпретованість KAN

KAN мережі є дуже *інтерпретованими* та *застосовними в наукових задачах*: див. ретельне дослідження від авторів оригінальної роботи [Liu+24a].

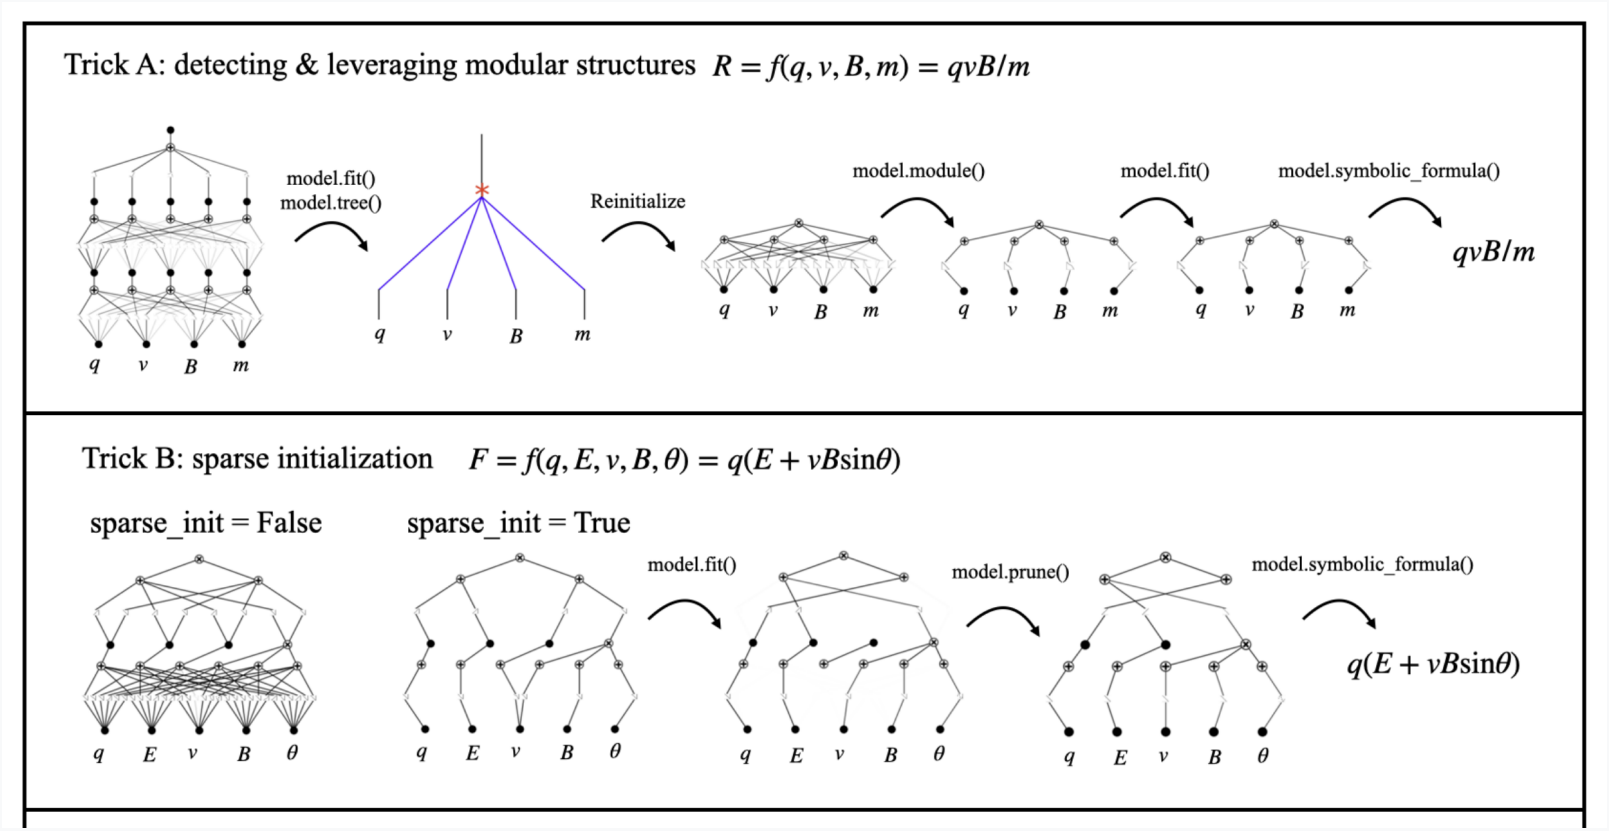


Рис.: Приклад інтерпретації KAN мережі з роботи [Liu+24a].

Конволюційні Мережі Колмогорова-Арнольда (KAN-CNN)

Мотивація використання CNN

Спробуємо “розгорнути” зображення 630×360 у вектор та під’єднаємо до MLP. Оцінимо кількість вхідних параметрів:

630



360

$$630 \times 360 = 226{,}800$$

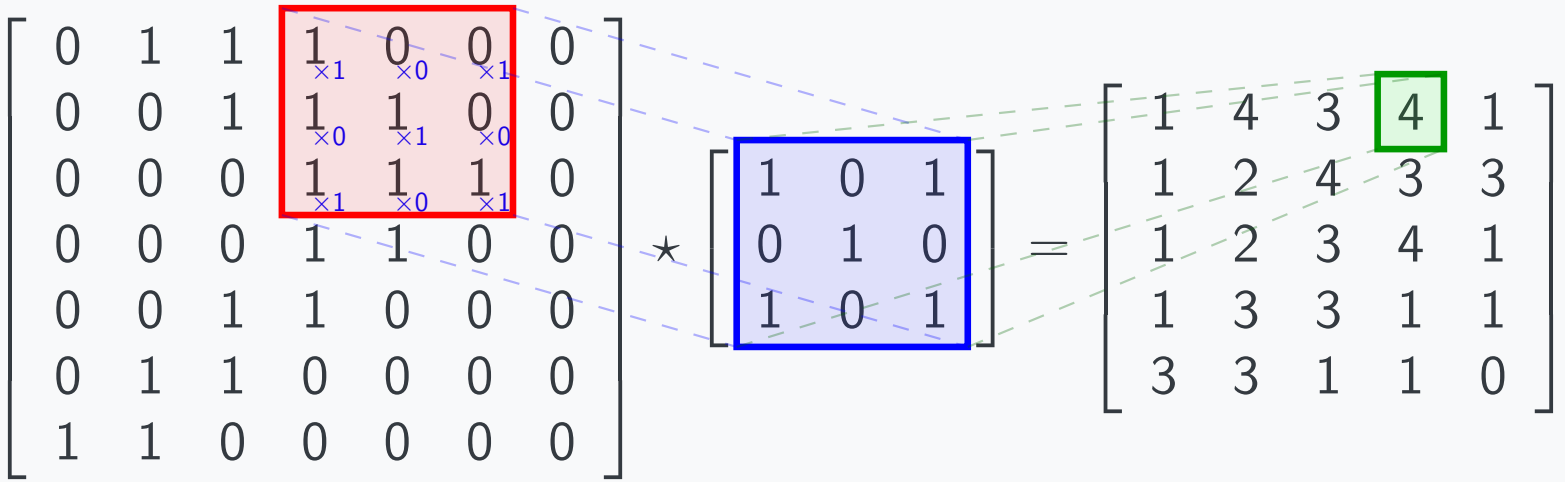


Конволюційна Нейронна Мережа (CNN)

Definition

Нехай $\boldsymbol{X} \in \mathbb{R}^{W \times H \times C}$ — набір з C зображень $W \times H$, та $\boldsymbol{K} \in \mathbb{R}^{f \times f \times C \times C'}$ — набір з C' фільтрів $f \times f \times C$. Тоді, згорткою з нелінійністю ϕ та страйдом s визначимо $\boldsymbol{Y} \in \mathbb{R}^{\frac{W}{s} \times \frac{H}{s} \times C'}$:

$$Y_{i,j,k} = \phi\left(\sum_{u=0}^{f-1}\sum_{v=0}^{f-1}\sum_{c=0}^{C-1} X_{i+u,j+v,c} K_{u,v,c,k} + \beta_{i,j,k}\right).$$



Приклад: Фільтри Собеля



$$* \underbrace{\begin{bmatrix} +1 & 0 & -1 \\ +2 & 0 & -2 \\ +1 & 0 & -1 \end{bmatrix}}_{x \text{ Sobel kernel}} =$$





$$* \underbrace{\begin{bmatrix} +1 & +2 & +1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}}_{y \text{ Sobel kernel}} =$$



Згортка Колмогорова-Арнольда

Definition

Нехай $\boldsymbol{X} \in \mathbb{R}^{W \times H \times C}$ — набір з C зображень (кількість каналів) розміру $W \times H$, та $\boldsymbol{K} \in \mathcal{F}^{f \times f \times C \times C'}$ — набір з C' фільтрів (ядер) розміру $f \times f \times C$, що складаються з параметризованих сплайнів. Тоді, результатом згортки буде нове зображення $\boldsymbol{Y} \in \mathbb{R}^{W \times H \times C}$:

$$Y_{i,j,k} = \sum_{u=0}^{f-1} \sum_{v=0}^{f-1} \sum_{c=0}^{C'-1} \phi_{u,v,c,k}(X_{i+u,j+v,k}),$$

де $\phi_{\boldsymbol{i}}(x) = \omega_{\boldsymbol{i},\beta}\beta(x) + \beta_{\boldsymbol{i},S}\sum_j c_{\boldsymbol{i},j}B_j(x)$, $\beta(x) = x\sigma(x)$.

$$\boldsymbol{K}_{\text{MLP}} = \begin{bmatrix} k_{1,1} & \cdots & k_{1,f} \\ \vdots & \ddots & \vdots \\ k_{f,1} & \cdots & k_{f,f} \end{bmatrix} \in \mathbb{R}^{f \times f} \qquad \boldsymbol{K}_{\text{KAN}} = \begin{bmatrix} \phi_{1,1}(x) & \cdots & \phi_{1,f}(x) \\ \vdots & \ddots & \vdots \\ \phi_{f,1}(x) & \cdots & \phi_{f,f}(x) \end{bmatrix} \in \mathcal{F}^{f \times f}$$

MLP згортка $f \times f$, складається з f^2 параметрів $k_{i,j} \in \mathbb{R}$.

KAN згортка $f \times f$, складається з f^2 функцій $\phi_{\boldsymbol{i}}(x) = \omega_{\boldsymbol{i},\beta}\beta(x) + \omega_{\boldsymbol{i},S}S(x)$.

Переваги KAN CNN

Традиційні CNN можуть виділяти лише лінійні ознаки зображення, що вимагає великої кількості шарів для побудови складних ознак.

Переваги KAN CNN

Традиційні CNN можуть виділяти лише лінійні ознаки зображення, що вимагає великої кількості шарів для побудови складних ознак.

KAN CNN можуть виділяти більш складні залежності по лише одному шару. Наприклад, наступна функція може бути апроксимована лише одним шаром KAN CNN:

$$\phi_{i,j}(x) = \begin{cases} \alpha_{\text{bright}} \cdot x, & \text{якщо } x \geq \tau_{i,j}, \\ \alpha_{\text{dark}} \cdot x, & \text{інакше.} \end{cases}$$

Експеримент

MNIST Датасет

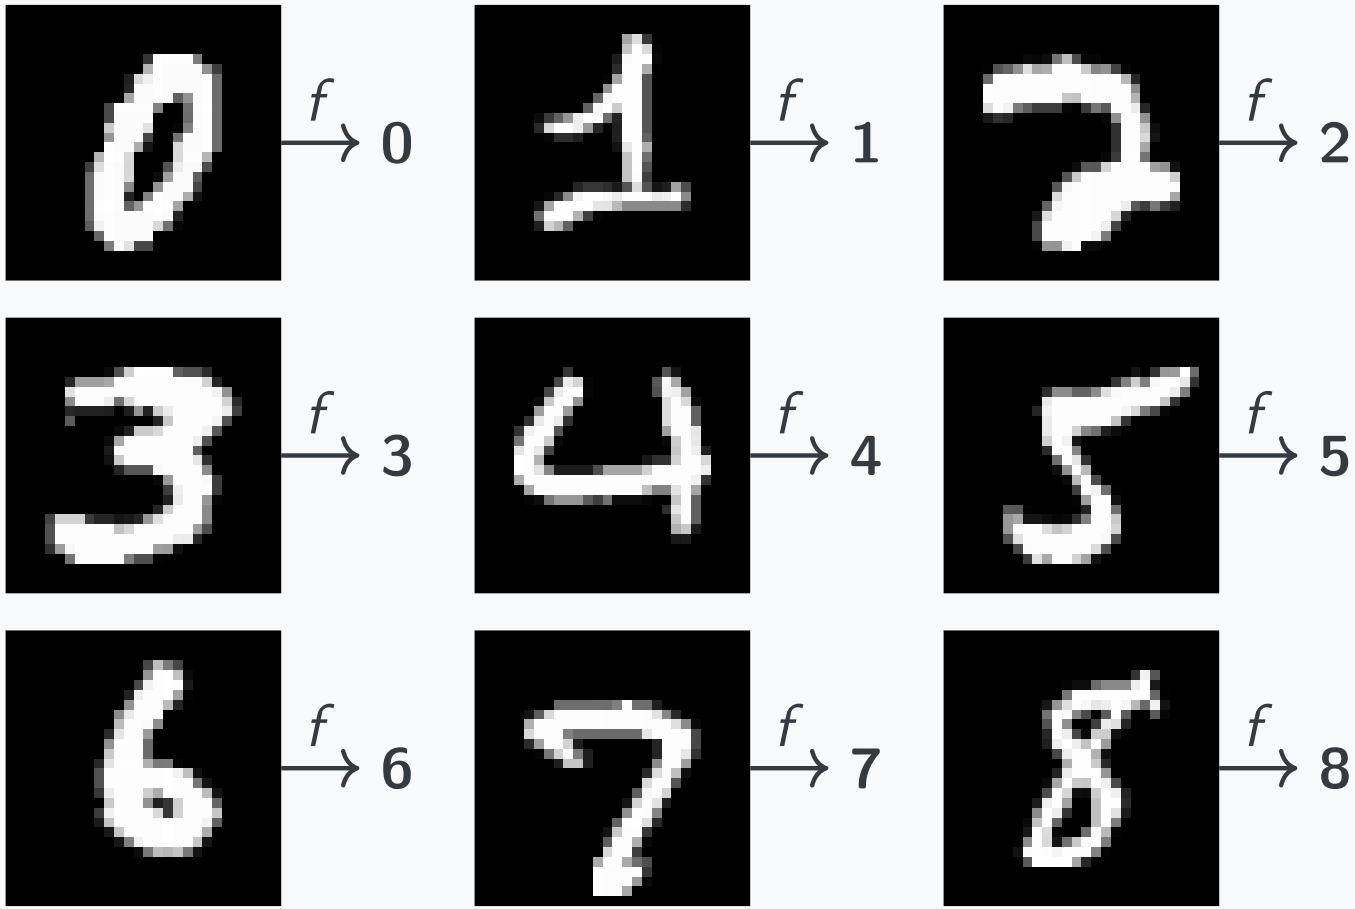


Рис.: Приклад класифікації цифр. Маючи зображення $X \in \mathbb{R}^{W \times H}$, наша функція дає дискретне передбачення $f(X) \in \{0, \ldots, 9\}$ — цифра, яка зображена на зображенні X.

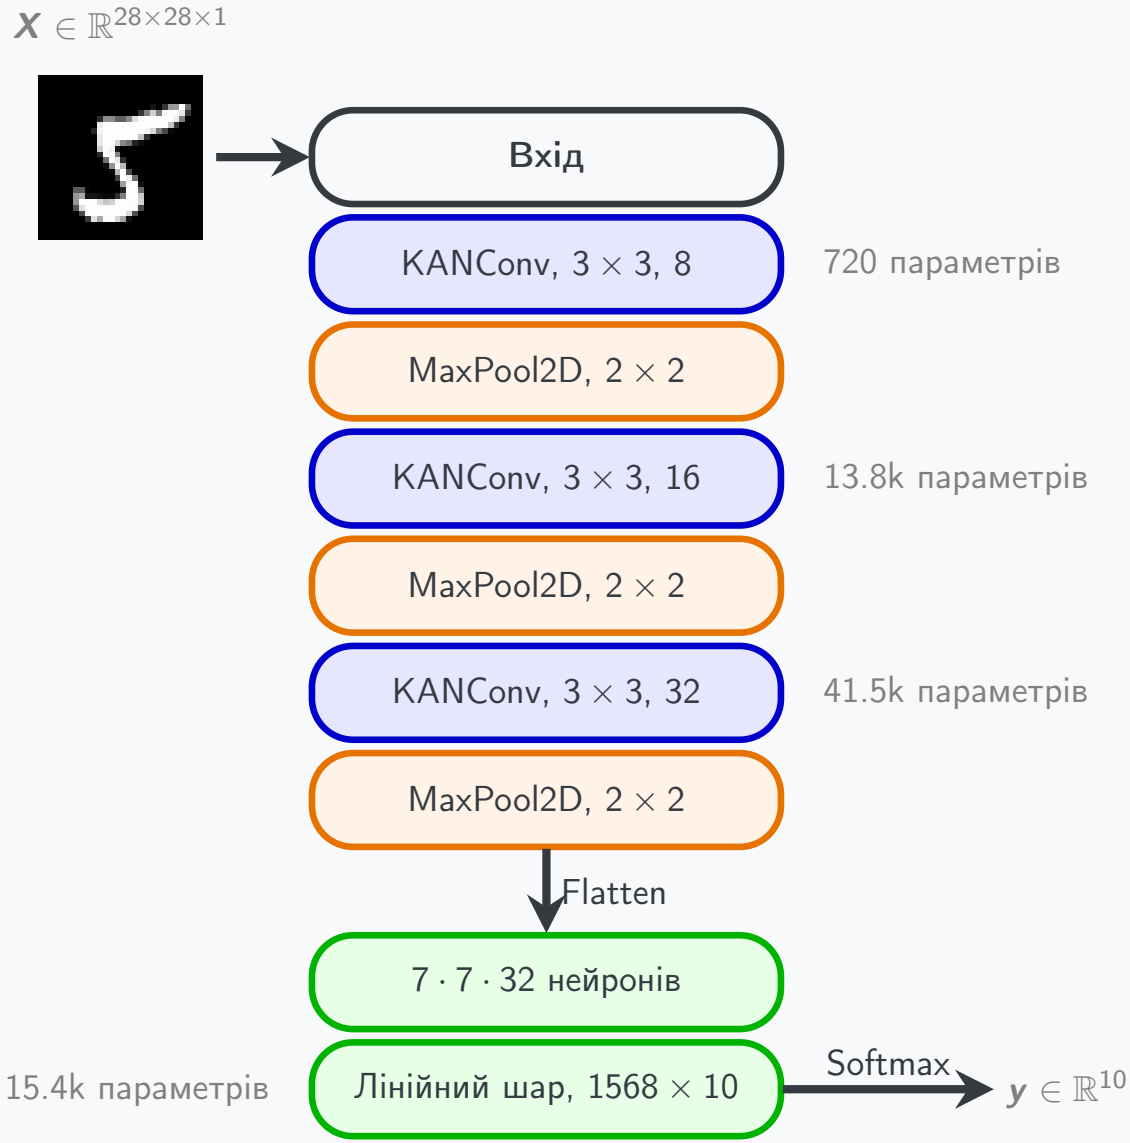


Рис.: Архітектура нейронної мережі на основі конволюційних шарів Колмогорова-Арнольда (CKAN).

Тренування

https://github.com/ZamDimon/convolutional-kan

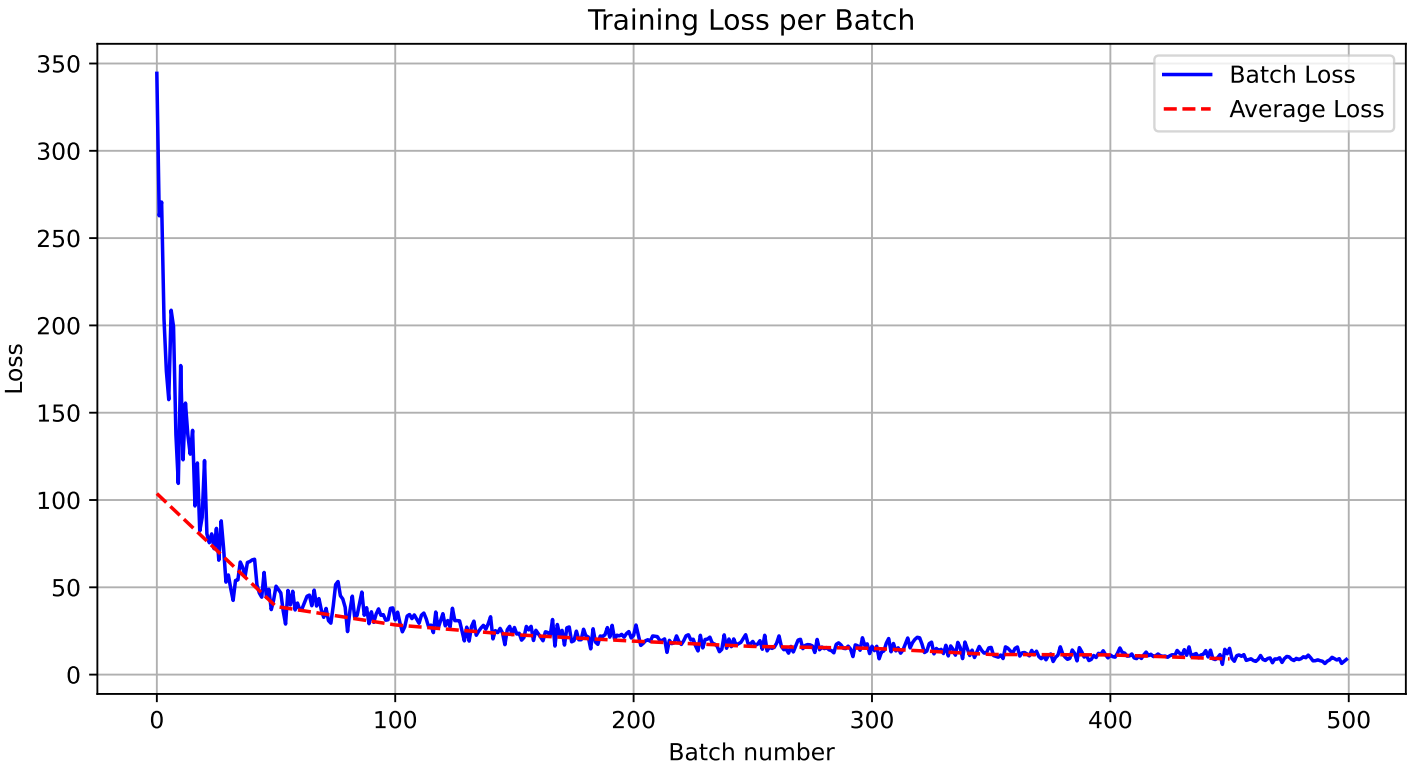


Рис.: Крива тренування нейронної мережі на основі конволюційних шарів Колмогорова-Арнольда (CKAN).

Висновки

- Досягнута точність на тестовому наборі MNIST **87.8%**.
- F_1 міра дорівнює **87.2%**.

Висновки

- Досягнута точність на тестовому наборі MNIST **87.8%**.
- F_1 міра дорівнює **87.2%**.
- Час тренування приблизно $\times 50$ в порівнянні з традиційними CNN: процес тренування дуже довгий, як і зазначено в оригінальній роботі [Liu+24b]. Причина — погана паралелізованість B-сплайнів.

Висновки

- Досягнута точність на тестовому наборі MNIST **87.8%**.
- F_1 міра дорівнює **87.2%**.
- Час тренування приблизно $\times 50$ в порівнянні з традиційними CNN: процес тренування дуже довгий, як і зазначено в оригінальній роботі [Liu+24b]. Причина — погана паралелізованість B-сплайнів.
- Проте, за такої саме MLP архітектури з класичними `Conv2D` шарами, точність MLP моделі була близько 85% — отже, KAN конволюції несуть більше інформації.

Висновки

- Досягнута точність на тестовому наборі MNIST **87.8%**.
- F_1 міра дорівнює **87.2%**.
- Час тренування приблизно $\times 50$ в порівнянні з традиційними CNN: процес тренування дуже довгий, як і зазначено в оригінальній роботі [Liu+24b]. Причина — погана паралелізованість B-сплайнів.
- Проте, за такої саме MLP архітектури з класичними `Conv2D` шарами, точність MLP моделі була близько 85% — отже, KAN конволюції несуть більше інформації.

Висновок

Конволюційні шари Колмогорова-Арнольда (KAN-CNN) можуть бути використані для побудови глибоких нейронних мереж, але поки вони дуже повільні та нестабільні. Потрібно більше досліджень для оптимізації їх тренування.

Література I

[Ben+21] Emily M. Bender та ін. “On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?” В: *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*. FAccT ’21. Virtual Event, Canada: Association for Computing Machinery, 2021, с. 610—623. ISBN: 9781450383097. DOI: 10.1145/3442188.3445922. URL: https://doi.org/10.1145/3442188.3445922.

[Cyb89] G. Cybenko. “Approximation by superpositions of a sigmoidal function”. В: *Mathematics of Control, Signals and Systems* 2.4 (1989), с. 303—314. DOI: 10.1007/BF02551274. URL: https://doi.org/10.1007/BF02551274.

Література II

[Kuz+24] Oleksandr Kuznetsov та ін. “AttackNet: Enhancing biometric security via tailored convolutional neural network architectures for liveness detection”. В: *Computers & Security* 141 (2024), с. 103828. ISSN: 0167-4048. DOI: https://doi.org/10.1016/j.cose.2024.103828. URL: https://www.sciencedirect.com/science/article/pii/S0167404824001299.

[KZF24] Oleksandr Kuznetsov, Dmytro Zakharov та Emanuele Frontoni. “Deep learning-based biometric cryptographic key generation with post-quantum security”. В: *Multimedia Tools and Applications* 83.19 (2024), с. 56909—56938. DOI: 10.1007/s11042-023-17714-7. URL: https://doi.org/10.1007/s11042-023-17714-7.

Література III

[Liu+24a] Ziming Liu та ін. “Kan 2.0: Kolmogorov-arnold networks meet science”. В: *arXiv preprint arXiv:2408.10205* (2024).

[Liu+24b] Ziming Liu та ін. “Kan: Kolmogorov-arnold networks”. В: *arXiv preprint arXiv:2404.19756* (2024).

[N57] Kolmogorov A. N. “On the Representation of Continuous Functions of one Variable and Addition”. В: *Doklady Akademii Nauk SSSR* 144 (1957), с. 679—681. URL: https://cir.nii.ac.jp/crid/1571980075616322176.

Література IV

[ZKF24] Dmytro Zakharov, Oleksandr Kuznetsov та Emanuele Frontoni. “Unrecognizable yet identifiable: Image distortion with preserved embeddings”. В: *Engineering Applications of Artificial Intelligence* 137 (2024), с. 109164. ISSN: 0952-1976. DOI: https://doi.org/10.1016/j.engappai.2024.109164. URL: https://www.sciencedirect.com/science/article/pii/S0952197624013228.

Дякую за Вашу Увагу!



Щільність у функціональному просторі

Definition

Нехай $(\mathcal{F}, \|\cdot\|)$ — нормований простір. Підмножина $\mathcal{G} \subset \mathcal{F}$ називається **щільною** в $\mathcal{F}$, якщо замикання $\mathcal{G}$ збігається з $\mathcal{F}$, тобто $\overline{\mathcal{G}} = \mathcal{F}$.

Еквівалентне визначення

Для будь-якої функції $f \in \mathcal{F}$ та для будь-якого $\varepsilon > 0$, існує функція $g \in \mathcal{G}$ така, що $\|f - g\| < \varepsilon$.

Теорема Вейєрштрасса про апроксимацію

Theorem (Weierstrass, 1885)

Нехай $f \in C([a,b])$ — неперервна функція на замкненому інтервалі. Для будь-якого $\varepsilon > 0$ існує поліном $P(x)$ такий, що для всіх $x \in [a,b]$ виконується нерівність:

$$|f(x) - P(x)| < \varepsilon$$

Висновок

Множина всіх поліноміальних функцій $\mathbb{R}[x]$ є щільною у просторі неперервних функцій $C([a,b])$ відносно норми рівномірної збіжності $\|\cdot\|_\infty$.

$$\|\phi\|_\infty = \sup_{x \in [a,b]} |\phi(x)|$$

Визначення: Простір Лебега L^p

Definition

Нехай $(\mathcal{X}, \mathcal{F}, \mu)$ — простір з мірою. Для $p \in [1, \infty)$, **простір Лебега** $L^p(\mathcal{X})$ — це множина всіх $\mathcal{F}$-вимірних функцій $f : \mathcal{X} \to \mathbb{R}$, для яких скінченна L^p-норма:

$$\|f\|_p := \left(\int_{\mathcal{X}} |f|^p \, d\mu \right)^{1/p} < \infty$$

Для $p = \infty$, $L^\infty(\mathcal{X})$ — це простір обмежених функцій з нормою:

$$\|f\|_\infty := \sup_{x \in \mathcal{X}} |f(x)| < \infty$$