Контрольна Робота з Математичної Статистики #1

Захаров Дмитро 26 жовтня, 2024

Варіант 5

Зміст

1	Вправа 1. Візуалізація вибіркових даних	2
2	Вправа 2. Довірчий інтервал для математичного сподівання	5
3	Вправа 3. Довірчий інтервал для дисперсії	7
4	Вправа 4. Перевірка гіпотези про математичне сподівання	9
5	Вправа 5	11

1 Вправа 1. Візуалізація вибіркових даних

Умова. Отримані наступні вибіркові дані про час безвідмовної роботи бурових штанг (у хвилинах): 280; 188; 190; 220; 288; 190; 190; 190; 280; 280; 190; 190; 300. Побудувати вибіркову функцію розподілу, гістограму вибірки та полігон частот. Знайти вибіркове середнє, вибіркову дисперсію і незміщену оцінку дисперсії.

Розв'язання. Отже, спочатку побудуємо таблицю частот:

3 начення t_i	Частота ν_i
188	1
190	6
220	1
280	3
288	1
300	1

Наближено, ми вважаємо, що якщо T — наша випадкова величина, що дорівнює часу безвідмовної роботи бурових штанг, то $\Pr[T=t_i]=\nu_i/\sum_{j=1}^n\nu_j$ для вибірки $\{(t_i,\nu_i)\}_{1\leq i\leq n}$. В нашому конкретно випадку, маємо наступний розподіл:

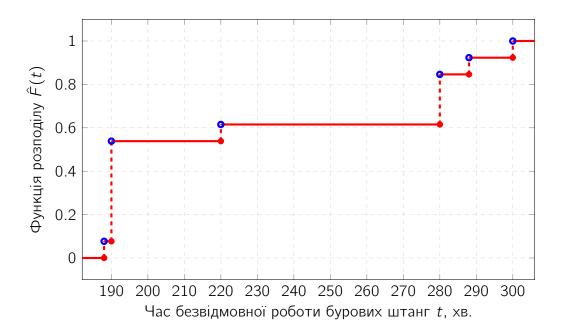
$$Pr[T = 188] = Pr[T = 220] = Pr[T = 288] = Pr[T = 300] = \frac{1}{13}$$

 $Pr[T = 190] = \frac{6}{13}$, $Pr[T = 280] = \frac{3}{13}$

Отже, вибіркова функція розподілу виглядає наступним чином:

$$\hat{F}_{T}(t) = \begin{cases} 0, & t \le 188, \\ \frac{1}{13}, & 188 < t \le 190, \\ \frac{7}{13}, & 190 < t \le 220, \\ \frac{8}{13}, & 220 < t \le 280, \\ \frac{11}{13}, & 280 < t \le 288, \\ \frac{12}{13}, & 288 < t \le 300, \\ 1, & t > 300. \end{cases}$$

Отже, зобразимо графік вибіркової функції розподілу:



Тепер побудуємо гістограму вибірки. Для цього візьмемо наступні вузли:

$$a_1 = 185$$
, $a_2 = 189$, $a_3 = 210$, $a_4 = 275$, $a_5 = 285$, $a_6 = 290$, $a_7 = 310$.

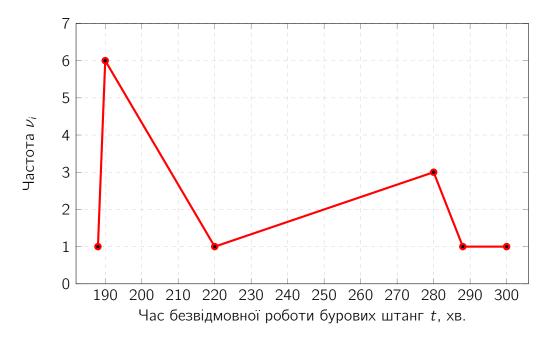
Далі будуємо гістограму наступним чином: зображуємо прямокутники, причому прямокутник i розташований між a_i та a_{i+1} вузлом, а його висота дорівнює $h_i = \nu_i/n\ell_i$ для $\ell_i = a_{i+1} - a_i$. Тут, ν_i – кількість данних на відрізку (a_i, a_{i+1}) . Отже, маємо:

$$h_1 \approx 0.0192$$
, $h_2 \approx 0.0220$, $h_3 \approx 0.0012$, $h_4 \approx 0.02308$, $h_5 \approx 0.01538$, $h_6 \approx 0.0038$.

Можна переконатись, що при цьому площа під графіком $\sum_{i=1}^n h_i \ell_i = 1$.



Нарешті, **полігон частот** це просто лінія, що з'єднує $\{(t_i, \nu_i)\}_{1 \leq i \leq n}$, тому маємо



Отже, тепер можемо порахувати вибіркове середнє. Воно обчислюється за формулою:

$$\overline{t} = \frac{1}{n} \sum_{i=1}^{n} t_i \nu_i, \ n := \sum_{j=1}^{n} \nu_j.$$

В нашому випадку,

$$\overline{t} = \frac{1}{13} \cdot (188 \times 1 + 190 \times 6 + 220 \times 1 + 280 \times 3 + 288 \times 1 + 300 \times 1) \approx 228.9$$

Тепер, вибіркова дисперсія обчислюється за формулою:

$$\overline{\sigma}_T^2 = \frac{1}{n} \sum_{i=1}^n t_i^2 \nu_i - \overline{t}^2.$$

В нашому випадку,

$$\overline{\sigma}_{T}^{2} = \frac{1}{13} \cdot (188^{2} \times 1 + 190^{2} \times 6 + 220^{2} \times 1 + 280^{2} \times 3 + 288^{2} \times 1 + 300^{2} \times 1) - 228.9^{2} \approx 2100^{2}$$

У свою чергу, незміщена оцінка дисперсії обчислюється за формулою:

$$\hat{\sigma}_T^2 = \frac{n}{n-1} \overline{\sigma}_T^2 = \frac{13}{12} \cdot 2100 \approx 2280$$

Відповідь. Вибіркова функція розподілу, гістограма вибірки та полігон частот зображені у розв'язку. Вибіркове середнє $\overline{t}\approx 228.9$, вибіркова дисперсія $\overline{\sigma}_T^2\approx 2100$, і незміщена оцінка дисперсії $\hat{\sigma}_T^2\approx 2280$.

2 Вправа 2. Довірчий інтервал для математичного сподівання

Умова. В таблиці \mathcal{D} , яка приведена нижче, вказана кількість лампочок, час горіння (в тис. годин) яких потрапило у відповідний проміжок. Для довірчої ймовірності $\alpha=0.96$ та середнього квадратичного відхилення $\sigma=0.01$ часу горіння побудувати довірчий інтервал для середнього часу горіння лампочки.

Час горіння	[2.1, 2.2)	[2.2, 2.3)	[2.3, 2.4)	[2.4, 2.5)	[2.5, 2.6)	[2.6, 2.7)
Число лампочок	2	8	22	40	12	10

Розв'язання. Будемо вважати, що наближено кількість лампочок ξ роподілена нормально, себто $\xi \sim \mathcal{N}(\mu, \sigma^2)$. Математичне сподівання μ ми маємо оцінити, а $\sigma = 0.01$ дано. Нам треба підібрати інтервал $\mathcal{I}_{\alpha} = (\ell(\mathcal{D}), u(\mathcal{D}))$ так, щоб $\Pr[\mu \in \mathcal{I}_{\alpha}] = \alpha$.

Скористаємось наступною теоремою.

Theorem 2.1. Про довірчий інтеграл математичного сподівання нормального за- кону. Нехай $\xi \sim \mathcal{N}(\mu, \sigma^2)$ і ми маємо вибірку $\mathcal{D} = (x_1, \dots, x_n) \sim \xi$. Тоді, довірчий інтервал \mathcal{I}_{α} для математичного сподівання можна покласти як:

$$\mathcal{I}_{\alpha} = \left(\overline{\mu} - \frac{z_{\alpha}\sigma}{\sqrt{n}}, \overline{\mu} + \frac{z_{\alpha}\sigma}{\sqrt{n}}\right), \quad z_{\alpha} := \Phi_0^{-1}\left(\frac{\alpha}{2}\right).$$

Себто, для цього інтервала виконується умова $\Pr[\mu \in \mathcal{I}_{\alpha}] = \alpha$.

Отже, нам залишилось порахувати всі значення. Маємо груповані дані, тому набір \mathcal{D} можна розглядати як вибірку з n=94 елементів, де

$$\mathcal{D} = \{\underbrace{2.15, \dots, 2.15}_{2 \text{ рази}}, \underbrace{2.25, \dots, 2.25}_{8 \text{ разів}}, \underbrace{2.35, \dots, 2.35}_{22 \text{ рази}}, \underbrace{2.45, \dots, 2.45}_{40 \text{ разів}}, \dots \}.$$

В цьому випадку вибіркове середнє $\overline{\mu}=\frac{1}{n}\sum_{i=1}^m x_i\approx 2.4372$. Згідно таблиці, маємо величину $z_{\alpha}=\Phi_0^{-1}(0.48)\approx 2.055$, а тому

$$\Pr\left[2.4372 - \frac{2.055 \times 0.01}{\sqrt{94}} < \mu < 2.4372 + \frac{2.055 \times 0.01}{\sqrt{94}}\right] = \alpha.$$

Величина $2.055 \times 0.01/\sqrt{94} \approx 0.0021$. А тому наш інтервал приблизно:

$$\mathcal{I}_{0.96} = (2.4372 - 0.0021, 2.4372 + 0.0021).$$

Відповідь. $\mathcal{I}_{0.96} \approx (2.43512, 2.43935).$

Додаток (програма). Для того, щоб переконатись, що в нас дійсно все працює, напишемо програму на мові *Python*, що реалізує цей алгоритм. Наводимо його нижче.

```
1 # Importing necessary libraries
```

² import numpy as np

³ from scipy.special import erf, erfinv

```
4
   def laplace_function(x: float) -> float:
5
6
7
        Given a float x, this function returns the value of the Laplace
        \hookrightarrow function at x, which
        is an integral of \exp(-t^2/2)/\operatorname{sqrt}(2\pi) from 0 to x.
8
        0.000
9
10
       return erf(x/np.sqrt(2))/2.0
11
12
   def inverse_laplace_function(x: float) -> float:
13
14
15
       Given a float x, this function returns the inverse of the
        \hookrightarrow Laplace function at x
        0.00\,0
16
       r = 1
17
18
        STEPS_FOR_FINDING_INVERSE = 10000
19
       for _ in range(STEPS_FOR_FINDING_INVERSE):
20
21
            r = r * x / laplace_function(r)
22
23
       return r
24
25
   def get_mean_credible_interval(dataset: np.ndarray,
26
                                      variance: float,
                                      credibility_prob: float) -> [float,
27
                                      → float]:
28
29
        Given a dataset, consisting of an array of floats, and variance
        this function returns the credible interval for the mean of the
30
        \hookrightarrow dataset.
        0.00\,0
31
32
       mu = np.mean(dataset) # Getting the mean
33
       n = len(dataset) # Getting the number of data points
34
        z_alpha = inverse_laplace_function(credibility_prob/2) # Getting
35
        \hookrightarrow the z_alpha value
36
       return (mu - z_alpha * np.sqrt(variance/n), mu + z_alpha *
37
        → np.sqrt(variance/n))
38
   dataset = [2.15]*2+[2.25]*8+[2.35]*22+[2.45]*40+[2.55]*12+[2.65]*10
39
   print(get_mean_credible_interval(dataset, 0.01**2, 0.96))
```

Вихід з цієї програми: (2.4351157622922854, 2.439352322814098).

3 Вправа 3. Довірчий інтервал для дисперсії

Умова. У деяких містах України отримані наступні дані про вартість споживчого кошика (в тис. грн) 196; 208; 196; 208; 208; 222; 216; 227; 222; 216; 222; 216; 222; 227; 240; 240; 240; 240; 240; 240; 227; 227; 227. Для довірчої ймовірності $\alpha=0.9$ побудувати довірчий інтервал для дисперсії вартості споживчого кошика міст України.

Розв'язання. Як і в минулому прикладі, будемо вважати, що вартість споживчого кошика (в тис. грн) ξ роподілена нормально, себто $\xi \sim \mathcal{N}(\mu, \sigma^2)$. У цій вибірці ми не знаємо ані математичного сподівання, ані дисперсії. Нам треба підібрати інтервал $\mathcal{I}_{\alpha} = (\ell(\mathcal{D}), u(\mathcal{D}))$ так, щоб $\Pr[\sigma^2 \in \mathcal{I}_{\alpha}] = \alpha$.

Скористаємось наступною теоремою.

Theorem 3.1. Про довірчий інтеграл дисперсії нормального закону. Нехай $\xi \sim \mathcal{N}(\mu,\sigma^2)$ і ми маємо вибірку $\mathcal{D}=(x_1,\ldots,x_n)\sim \xi$. Тоді, якщо позначити $q:=1-\alpha$, довірчий інтервал \mathcal{I}_{α} для дисперсії можна покласти як:

$$\mathcal{I}_{lpha}=\left(rac{n\overline{\sigma}_{X}^{2}}{eta},rac{n\overline{\sigma}_{X}^{2}}{oldsymbol{\gamma}}
ight)$$
, $eta=\chi_{n-1,q/2}^{2}$, $eta=\chi_{n-1,1-q/2}^{2}$

Себто, для цього інтервала виконується умова $\Pr[\sigma^2 \in \mathcal{I}_{lpha}] = lpha.$

Отже, залишається лише порахувати всі значення. Маємо вибірку з n=25 елементів. Середнє значення $\overline{\mu}_X=\frac{1}{n}\sum_{i=1}^n x_i=223.32$, а отже вибіркова дисперсія

$$\overline{\sigma}_X^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \overline{\mu}_X^2 \approx 177.34.$$

Знайдемо коефіцієнти lpha та eta. Маємо q=1-lpha=0.1. Отже, згідно таблиці знаходимо

$$\chi^2_{24,0.05} \approx 36.42$$
, $\chi^2_{24,0.95} \approx 13.85$.

Таким чином, наш інтервал:

$$\mathcal{I}_{0.9} = \left(\frac{25 \times 177.34}{36.42}, \frac{25 \times 177.34}{13.85}\right) \approx (121.73, 320.11).$$

Відповідь. $\mathcal{I}_{0.9} = (121.73, 320.11).$

Додаток (програма). Для того, щоб переконатись, що в нас дійсно все працює, напишемо програму на мові *Python*, що реалізує цей алгоритм. Наводимо його нижче.

```
8
            Given a dataset, consisting of an array of floats,
            this function returns the credible interval for the variance
9
            \hookrightarrow of the dataset.
            0.00
10
11
           mu = np.mean(dataset) # Getting the mean
12
           variance = np.mean(dataset**2) - mu**2 # Getting the variance
13
           n = len(dataset) # Getting the number of data points
14
15
           q = 1 - alpha # Getting the q value
16
17
           beta = chi2.isf(q/2, n-1)
            gamma = chi2.isf(1-q/2, n-1)
18
19
20
           return (n*variance/beta, n*variance/gamma)
21
22
       dataset = np.array([
23
            196, 208, 196, 208, 208, 222, 216, 227, 222, 216, 222, 216,
            216, 222, 227, 240, 240, 240, 240, 240, 240, 240, 227, 227,
24
       ])
25
26
27
       print(get_variance_credible_interval(dataset, 0.9))
```

Вихід з цієї програми: (121.74753617946827, 320.14037634618154).

4 Вправа 4. Перевірка гіпотези про математичне сподівання

Умова. Номінальний опір для резисторів, які виготовляються, складає 2000Ω . Для контролю відібрана партія з резисторів. В результаті вимірювання опору кожного зразка з точністю до 5Ω отримані наступні значення: 2130; 2090; 2030; 2080; 1920; 2020; 2015; 2000; 2045; 1940; 1980; 1970. Чи можна відхилення від номіналу (2000Ω) розглядати як випадкові (допустимі) або, навпаки, результати вказують на те, що опір резисторів відрізняється від номіналу?

Розв'язання. Введемо довірчу ймовірність $\alpha=0.95$. Будемо вважати, що точність вимірювання — це середньоквадратичне відхилення $\sigma=5\Omega$. Тоді, введемо дві гіпотези:

- \mathcal{H}_0 : математичне сподівання $\mu = \mu_0$, де $\mu_0 = 2000\Omega$.
- \mathcal{H}_1 : обернене твердження, тобто $\mu = \mu_0$, де $\mu_0 \neq 2000\Omega$.

Нехай R — випадкова величина, що описує опір резистора. Тоді, будемо вважати, що $R \sim \mathcal{N}(\mu_R, \sigma^2)$, де μ_R нам невідоме, а $\mathcal{D} = (r_1, \ldots, r_n)$ — наша вибірка. Отже, знайдемо вибіркове середнє значення нашої вибірки:

$$\bar{r} = \frac{1}{n} \sum_{i=1}^{n} r_i \approx 2018.33.$$

Згідно теорії, випадкова величина $y=\sqrt{n}(\overline{r}-\mu)/\sigma\sim\mathcal{N}(0,1)$. Отже, якщо гіпотеза \mathcal{H}_0 вірна, то замість μ підставляємо $\mu_0=2000\Omega$. Тоді $y=\sqrt{12}(2018.33-2000)/5\approx 12.7$. Як було сказано, довірча ймовірність $\alpha=0.95$. Для неї добре відомий квантиль $z_\alpha:=\Phi_0^{-1}(\alpha/2)=1.96$.

Бачимо, що 12.7 > 1.96, а отже ми відхиляємо гіпотезу \mathcal{H}_0 на користь \mathcal{H}_1 . Отже, можна вважати, що опір резисторів відрізняється від номіналу. Це також достатньо добре видно і без додаткового підрахунку: як відомо, більше 95% випадкових величин з нормального розподілу лежать в межах 2σ від математичного сподівання. Отже, якщо вибіркове середнє відрізняється від номіналу більше, ніж на 2σ , то це вже досить серйозний відхил від номіналу. Також, можна це підтвердити програмою нижче:

```
1 # Importing necessary libraries
  import numpy as np
   from scipy.special import erf, erfinv
   def laplace_function(x: float) -> float:
5
6
7
       Given a float x, this function returns the value of the Laplace
        \hookrightarrow function at x, which
       is an integral of \exp(-t^2/2)/\operatorname{sqrt}(2\pi) from 0 to x.
8
9
10
       return erf(x/np.sqrt(2))/2.0
11
12
13
   def inverse_laplace_function(x: float) -> float:
```

```
14
        Given a float x, this function returns the inverse of the
15
        \hookrightarrow \  \, \text{Laplace function at } x
        H/H/H
16
17
        r = 1
        STEPS_FOR_FINDING_INVERSE = 10000
18
19
20
        for _ in range(STEPS_FOR_FINDING_INVERSE):
            r = r * x / laplace_function(r)
21
22
23
        return r
24
25
   def test_hypothesis(dataset: np.ndarray,
26
                          std: float,
27
                          expected_mean: float,
                          alpha: float = 0.95) -> bool:
28
        \Pi_{-}\Pi_{-}\Pi
29
        Given a dataset, consisting of an array of floats, and standard
30
        \hookrightarrow deviation,
31
        tests whether the expected mean is true or not.
        0.00
32
33
34
        mu = np.mean(dataset) # Getting the mean
        n = len(dataset) # Getting the number of data points
35
36
        normed_diff = (mu - expected_mean) / (std/np.sqrt(n)) # Getting
        \hookrightarrow the normalized difference
        z_alpha = inverse_laplace_function(alpha/2) # Getting the
37
        \hookrightarrow z_alpha value
38
        print(f"Got normalized difference: {normed_diff}, z_alpha is:
39
        \hookrightarrow {z_alpha}")
        return np.abs(normed_diff) < z_alpha</pre>
40
41
42 dataset = [2130, 2090, 2030, 2080, 1920, 2020, 2015, 2000, 2045,

→ 1940, 1980, 1970]
43 result = test_hypothesis(dataset, 5, 2000, 0.95)
44 print("Hypothesis is true" if result else "Hypothesis is false")
```

Вихід з цієї програми: Got normalized difference: 12.701705922171714, z_alpha is: 1.9599639845400536, Hypothesis is false.

Відповідь. Опір резисторів відрізняється від номіналу.

5 Вправа 5

Умова. На одній з ділянок розсипного родовища золота досліджували можливість зниження витрат на розвідку. При цьому замість частини запланованих шурфів були пробурені свердловини ударно-канатного буріння (витрати на буріння свердловин менші). Результати опробування шурфів на вміст золота (в кг/м³): 431; 397; 462; 457; 251; 221; 548; 478; 299; 541, свердловини: 322; 250; 225; 315; 399; 348; 192; 375; 381; 538; 198; 317; 293. Чи можна вважати, що в середньому результати опробування свердловин на наявність золота несуттєво відрізняються від результатів опробування шурфів?

Розв'язання. Отже, маємо вибірку вміст золота x_1, \ldots, x_n з генеральної сукупності шурфів X, а також вибірку вмісту y_1, \ldots, y_m з сукупності свердловини Y. Цілком логічно вважати X та Y незалежними та нормально розподіленими. Тобто нехай $X \sim \mathcal{N}(\mu_X, \sigma_X)$ та $Y \sim \mathcal{N}(\mu_Y, \sigma_Y)$. В нашому випадку ми не знаємо ані жодне з математичних сподівань μ_X та μ_Y , ані жодну з дисперсій σ_X^2 та σ_Y^2 . Вводимо дві гіпотези:

- \mathcal{H}_0 : $\mu_X = \mu_Y$ (основна гіпотеза).
- \mathcal{H}_1 : $\mu_X \neq \mu_Y$ (альтернативна гіпотеза).

Перевірити гіпотезу \mathcal{H}_0 ми можемо, припускаючи $\sigma_X^2 = \sigma_Y^2 = \sigma^2$. Введемо випадкову величину $\xi := \overline{x} - \overline{y}$, де

$$\overline{x} = \frac{1}{n} \sum_{i=1}^{n} x_i \approx 408.5, \quad \overline{y} = \frac{1}{m} \sum_{i=1}^{m} y_i \approx 320.$$

Тоді, як було доведено на лекції,

$$\xi \sim \mathcal{N}\left(\mu_X - \mu_Y, \frac{1}{n}\sigma_X^2 + \frac{1}{m}\sigma_Y^2\right)$$

Тому, цілком природньо ввести стандартно нормально розподілену випадкову величину:

$$\eta := rac{\overline{x} - \overline{y} - (\mu_X - \mu_Y)}{\sqrt{rac{1}{n} \cdot \sigma_X^2 + rac{1}{m} \cdot \sigma_Y^2}} \sim \mathcal{N}(0, 1).$$

Якщо б ми знали σ_X^2 , σ_Y^2 , то ми б могли одразу ввести довірчу ймовірність та дивитись, в яку частину нормального розподілу потрапляє вираз $(\overline{x} - \overline{y}) / \sqrt{\frac{1}{n} \cdot \sigma_X^2 + \frac{1}{m} \cdot \sigma_Y^2}$. Тут ми так зробити не можемо, тому продовжимо далі.

Як було сказано, припускаємо, що $\sigma_X^2 = \sigma_Y^2 = \sigma^2$. Тоді, маємо випадкову величину:

$$\eta = rac{\overline{x} - \overline{y} - (\mu_X - \mu_Y)}{\sigma \sqrt{rac{1}{n} + rac{1}{m}}} \sim \mathcal{N}(0, 1).$$

Отже, розглянемо випадкові дисперсії:

$$\overline{\sigma}_X^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \overline{x}^2 \approx 11965, \quad \overline{\sigma}_Y^2 = \frac{1}{m} \sum_{i=1}^m y_i^2 - \overline{y}^2 \approx 8250.$$

За теоремою про розподіл вибіркової дисперсії, $n\overline{\sigma}_X^2/\sigma^2 \sim \chi_{n-1}^2$, $m\overline{\sigma}_Y^2/\sigma^2 \sim \chi_{m-1}^2$. Враховуючи незалежність цих величин і теорему про стійкість розподілу χ^2 , маємо

$$\zeta = \frac{n\overline{\sigma}_X^2}{\sigma^2} + \frac{m\overline{\sigma}_Y^2}{\sigma^2} \sim \chi_{m+n-2}^2.$$

Згідно лекції, величини η та ζ є незалежними. Тому утворимо наступну статистику:

$$\tau = \frac{\eta}{\sqrt{\zeta/(n+m-2)}} = \frac{\overline{x} - \overline{y} - (\mu_X - \mu_Y)}{\sqrt{n\overline{\sigma}_X^2 + m\overline{\sigma}_Y^2}} \sqrt{\frac{nm(m+n-2)}{m+n}} \sim \mathcal{ST}_{n+m-2}$$

Якщо ж основна гіпотеза \mathcal{H}_0 правильна, то

$$\tau = \frac{\overline{x} - \overline{y}}{\sqrt{n\overline{\sigma}_X^2 + m\overline{\sigma}_Y^2}} \sqrt{\frac{nm(m+n-2)}{m+n}} \sim \mathcal{ST}_{n+m-2}$$

Підставимо конкретні значення. Маємо:

$$\tau = \frac{408.5 - 320}{\sqrt{10 \times 11965 + 13 \times 8250}} \sqrt{\frac{10 \times 13 \times 21}{23}} \approx 2.024.$$

Оберемо довірчу ймовірність $\alpha=0.95$, а отже відповідний рівень значущості $q:=1-\alpha=0.05$. За таблицею розподілу Стьюдента маємо $t_{n+m-2,q}=t_{21,0.05}\approx 2.08$. Оскільки $|\tau|< t_{n+m-2,q}$, то вважаємо гіпотезу \mathcal{H}_0 правильною. Отже, можна вважати, що в середньому результати опробування свердловин на наявність золота несуттєво відрізняються від результатів опробування шурфів.

Відповідь. В середньому результати опробування свердловин на наявність золота несуттєво відрізняються від результатів опробування шурфів.